

Myanmar Syllable Handwriting Recognition

Proposed by Dr. Ye Kyaw Thu

Language Understanding Lab., Myanmar

March 29, 2026

- မြန်မာစာအတွက် **Handwriting Recognition** သုတေသနက အများကြီး ဆက်လုပ်ဖို့ လိုအပ်နေသေး
- **Syllable level** အတွက် စုထားတဲ့ ဒေတာလည်း မရှိသေး
- ခက်တာက လက်ရှိသုံးနေကြတဲ့ မြန်မာစာမှာ **syllable** အရေအတွက်က လေးထောင်ကျော်တယ် (ရှိတဲ့ ဒေတာထဲကနေ ဆွဲထုတ် လေ့လာကြည့်ချက်အရ)
- ပုံ ကိုပဲအခြေခံပြီး မြန်မာစာအတွက် **handwritten recognition** လုပ်ဖို့က **accuracy** မကောင်းနိုင်ဘူး
- ငါတို့ ဝိုင်းရေးလိုက်ကြပြီး ရလာတဲ့ ဒေတာနဲ့ **experiment** အသစ်တစ်ခု လုပ်ချင်တယ်

Myanmar Syllable Handwriting Collector




Figure: User interface for handwriting collection

Syllable Frequency List

- ဆရာတို့ LU Lab. ရဲ့ myMono corpus ကနေ frequency အလိုက် စီထားတဲ့ ဖိုင်ပါ။ အသုံး အများဆုံး syllable က ထိပ်ဆုံးမှာပါ။
- Manual cleaning လည်း လုပ်နိုင်သလောက် လုပ်ထားတယ်။

52	လည်း · 15012
53	သာ · 14787
54	မယ် · 14585
55	ပေး · 14522
56	ထား · 13898
57	ပြော · 13332
58	ဒါ · 13324
59	ရင် · 13266
60	ခု · 13193
61	အိမ် · 13111
62	ဘာ · 13029
63	သော · 12893
64	၏ · 12757
65	ဗျား · 12647
66	လက် · 12613
67	မှ · 12453
68	ရဲ့ · 12161
69	လှ · 11986
70	နှစ် · 11923
71	ကား · 11893
72	သား · 11583
73	ဦး · 11263

Figure: Syllable Frequency List File

Data Format

1	STROKE · 1
2	354 · 159 · 1774414222 · 6893592
3	353 · 159 · 1774414222 · 8499017
4	353 · 157 · 1774414222 · 8580172
5	353 · 155 · 1774414222 · 8742123
6	353 · 152 · 1774414222 · 8900118
7	353 · 151 · 1774414222 · 8993726
8	353 · 148 · 1774414222 · 914205
9	354 · 147 · 1774414222 · 9219673
10	355 · 146 · 1774414222 · 9309733
11	356 · 145 · 1774414222 · 9463055
12	356 · 144 · 1774414222 · 970369
13	358 · 144 · 1774414222 · 9900641
14	360 · 144 · 1774414223 · 0224345
15	365 · 144 · 1774414223 · 0260081
16	367 · 144 · 1774414223 · 0356107
17	370 · 145 · 1774414223 · 042647
18	373 · 148 · 1774414223 · 0514202
19	377 · 152 · 1774414223 · 0579634
20	379 · 156 · 1774414223 · 0694892

Figure: Data format for Myanmar syllable “ချစ်”

Online Handwriting Data Format

Key Idea: We use **online handwriting data**, which records the writing process, not just the final image.

Explanation:

- STROKE n : One pen-down to pen-up action
- Each line: x y $time$
 - ▶ x, y : spatial coordinates
 - ▶ $time$: timestamp (Unix time)

Advantages:

- Captures **shape + writing order + speed**
- More informative than static images
- Suitable for handwriting recognition systems

Conversion with “--color_mode single”

- python ./convert2image.py --dataset dataset --output single --color_mode single



Figure: Examples of images of --color_mode single

Conversion with “--color_mode stroke”

- python ./convert2image.py --dataset dataset --output stroke --color_mode stroke




Figure: Examples of images of --color_mode stroke

Conversion with “--color_mode time”

- python ./convert2image.py --dataset dataset --output time --color_mode time




Figure: Examples of images of --color_mode time

Stroke vs Time Visualization

- **Stroke Mode**

- ▶ Color per stroke
- ▶ Shows structure
- ▶ Good for stroke analysis

- **Time Mode**

- ▶ Color per time progression
- ▶ Shows writing flow
- ▶ Good for dynamic behavior analysis

Key Insight:

- Stroke → **What was drawn**
- Time → **How it was drawn**

Best Practice:

- Combine both for better handwriting recognition systems

3 Python Codes

- ပရိုဂရမ် သုံးပုဒ်ကို ဆရာ ပြင်ပေးထားပါတယ်။

```
(base) C:\Users\801680\.spyder-py3\lipitk>dir *.py
Volume in drive C has no label.
Volume Serial Number is 9C54-A208

Directory of C:\Users\801680\.spyder-py3\lipitk

03/26/2026  11:08 AM                5,540 convert2image.py
03/26/2026  11:09 AM                5,970 dataset_browser.py
03/26/2026  11:06 AM            11,827 hw_recognizer.py
               3 File(s)            23,337 bytes
               0 Dir(s)  26,430,398,464 bytes free
```

Figure: 3 Python programs

Python Code for Handwriting Data Collection

- `python hw_collector.py --help`
- How to run: `python hw_collector.py --file syl.txt`

```
(base) C:\Users\801680\.spyder-py3\lipitk>python hw_collector.py --help
usage: hw_collector.py [-h] --file FILE [--font_size FONT_SIZE]

Myanmar Syllable Handwritten Collector

optional arguments:
  -h, --help            show this help message and exit
  --file FILE
  --font_size FONT_SIZE

(base) C:\Users\801680\.spyder-py3\lipitk>_
```

Figure: Commandline help of `hw_collector.py`

Python Code for Browsing Recorded Dataset

- `python dataset_browser.py --help`
- How to run: `python dataset_browser.py --dataset dataset
textfile syl.txt`

```
(base) C:\Users\801680\.spyder-py3\lipitk>python dataset_browser.py --help
usage: dataset_browser.py [-h] [--dataset DATASET] --textfile TEXTFILE

LipITK Dataset Browser Tool

optional arguments:
  -h, --help            show this help message and exit
  --dataset DATASET     Dataset folder (default: dataset)
  --textfile TEXTFILE   Text file (one character per line)

(base) C:\Users\801680\.spyder-py3\lipitk>
```

Figure: Commandline help of dataset_browser.py

Handwriting Dataset Browser

- `python dataset_browser.py --dataset dataset --textfile syl.txt`




Figure: UI of Handwriting Dataset Browser

Text to Image Conversion Program

- `python convert2image.py --dataset dataset --output single --color_mode single`
- `python convert2image.py --dataset dataset --output stroke --color_mode stroke`
- `python convert2image.py --dataset dataset --output time --color_mode time`

```
(base) C:\Users\801680\.spyder-py3\lipitk>python convert2image.py --help
usage: convert2image.py [-h] [--dataset DATASET] [--output OUTPUT] [--size SIZE] [--format {png,jpg}]
                        [--color_mode {single,stroke,time}]

Convert LipiTK stroke dataset to images

optional arguments:
  -h, --help            show this help message and exit
  --dataset DATASET     Dataset folder
  --output OUTPUT       Output folder
  --size SIZE           Image size (default: 128)
  --format {png,jpg}    Image format
  --color_mode {single,stroke,time}
                        Color mode: single, stroke, time
```

Figure: Help screen of convert2image.py

Task to Do (Assignment-3)

- `hw_collector.py` ပရိုဂရမ်ကို သုံးပြီး ကိုယ့် လက်ရေးဒေတာကို စုပါ။
- စာလုံး တစ်လုံးချင်းစီကို အနည်းဆုံး ၃ ခါ ရေးပြီး တစ်ပုံချင်းစီကို `save` လုပ်သွားပါ။
- ပုံမှန်အတိုင်း ကိုယ်ရေးနေကျအတိုင်းပဲ ရေးသွားပါ
- `char/syllable` တစ်လုံးချင်းစီကို ၃ ခါ ထက်ပိုရေးနိုင်ရင် ရေးပါ။ သို့သော် သုံးပတ်အတွင်းမှာ `syl.txt` ဖိုင်ထဲမှာ ရှိတဲ့ စာလုံး အားလုံး လေးထောင်ကျော်ကို ပြီးအောင် ရေးမှ အဆင်ပြေမှာမို့ အဲဒါကိုလည်း သတိထားပါ။
- `coding` လုပ်နိုင်တဲ့သူက အနည်းဆုံး `approach` တစ်ခုကိုသုံးပြီး `handwriting recognition` လုပ်ကြည့်ပြီး ရလဒ်ကို တင်ပြပါ။ ဒေတာစုရင်းနဲ့ ဂရုပြုမိတဲ့ အချက်အလက်တွေကို မှတ်စုရေးပြီး တင်ပြပါ။
- ကိုယ့်နာမည်အပြည့်အစုံနဲ့ `dataset` ဖိုလ်ဒါကို `zip` လုပ်ပြီး ဆရာ့ဆီကို အီးမေးလ်နဲ့ ပို့ပေးပါ။ Email address: `yktnlp@gmail.com`
- **Deadline: 25 April 2026, Saturday**